RAG educativo bilingüe para problemas resueltos de Física y Matemáticas

Asignatura: Bases de Datos Avanzadas | Fecha: 11/11/2026 | Autor/a: Miguel Sánchez Rodríguez

1. Caso de uso y objetivo

Sistema de consulta académica que recupera problemas resueltos similares a una pregunta formulada en español o inglés, muestra los pasos de solución y cita el ejercicio de origen. El foco del proyecto es comparar estrategias de almacenamiento, indexación, filtrado SQL y recuperación semántica/híbrida en PostgreSQL y pgvector; la generación mediante LLM será una capa secundaria.

2. Fuentes, formatos y condiciones de uso

Fuente / URL	Formato e idioma	Volumen y licencia declarada
PolyUniMath HF: friederrr/PolyUniMath	Parquet · ES/EN (selección) Problema, solución y respuesta	4,29 M registros (~5,23 GB) en la fuente; 15.000 seleccionados. CC BY-NC 4.0.
PhysicsEval HF: IUTVanguard/PhysicsEval	JSON · EN Problema y solución elaborada	19.609 registros (~302 MB total); test.json: 1.962 (~30 MB), de los que se eligen 1.000. CC BY-SA 4.0.

Procedencia: PolyUniMath extrae ejercicios de PDF de Common Crawl; PhysicsEval recopila problemas de libros universitarios y fuentes educativas. Las licencias anteriores son las declaradas por los distribuidores, no una verificación de permisos sobre cada obra subyacente. Uso académico restringido y sin redistribución hasta aclarar derechos y atribuciones.

3. Corpus candidato y metadatos

Subconjunto	Documentos	Idioma
Matemáticas (PolyUniMath)	6.000	Español
Matemáticas (PolyUniMath)	9.000	Inglés
Física (PhysicsEval)	1.000	Inglés
TOTAL	16.000	ES + EN

Unidad documental: un problema autocontenido con enunciado, desarrollo y respuesta. Preprocesamiento: normalización de texto/LaTeX, eliminación de duplicados, soluciones no válidas, fragmentos dañados y referencias a imágenes ausentes. Selección de PolyUniMath desde shards 10, 11, 12 y 19; PhysicsEval desde test.json.

Metadatos por documento: document_id, language, domain, topic, difficulty, source_dataset, source_material y source_row. Permiten filtros relacionales, p. ej. idioma=es, materia=matemáticas, tema=álgebra y dificultad; source_row mantiene la trazabilidad.

4. Recuperación e implementación prevista

PostgreSQL 17 + pgvector: tablas de documentos, fragmentos (chunks), metadatos y embeddings; índices B-tree para filtros, búsqueda full-text y vectorial (exacta y ANN con HNSW). Comparación vector vs. FTS vs. híbrida, con y sin filtros SQL; evaluación de latencia, recall@k, precisión@k y cobertura multilingüe. Ingesta, fragmentación, consultas y evaluación implementadas en Python/SQL sin frameworks RAG de alto nivel.

Embeddings: intfloat/multilingual-e5-base (768 dimensiones, máximo 512 tokens). Chunks de 256 tokens, con 252 tokens útiles de texto tras prefijo y tokens especiales; prefijos exactos: «query: » y «passage: ». Modelo cargable con sentence-transformers 6.1.0 sin trust_remote_code.

5. Viabilidad preliminar: comprobación oficial

check_project.py ejecutado sobre 300 documentos aleatorios del corpus candidato (112 ES y 188 EN). Resultado: 8/8 verificaciones [OK]. Estima 52.693 chunks de 256 tokens para 16.000 documentos; dimensión 768, max_seq_length 512. Porcentaje de chunks en muestra: ES 24,2 % (239/988), EN 75,8 % (749/988). Rendimiento medido: 82,2 chunks/s en GPU CUDA; ~10 min para embeddings, sin incluir carga, fragmentación ni inserción. Las cantidades son estimaciones muestrales, no un recuento integral. La salida íntegra figura en el anexo.

6. Cinco preguntas reales de evaluación

Cada pregunta tiene documento de referencia identificable en la muestra. «Cross-lingual» indica que el idioma de la pregunta es distinto del documento recuperable.

P1 · ES → ES · Álgebra

Para $P(x)=3x^3-ax^2-bx+1$, si el resto al dividir entre $x+2$ es 3 y $x-1$ es factor, ¿cuánto valen a y b?

Respuesta esperada: a=−3; b=7. Fuente: math:es:AI-MO/QA_Full/00620/1834 | Parquet 11, fila 11836 · documento ES

P2 · EN → ES · Cross-lingual

For A(2,1), B(6,5), and C(5,1), what is the reflection of C across line AB?

Respuesta esperada: (2,4). Fuente: math:es:AI-MO/QA_Full/00679/575 | Parquet 11, fila 62576 · documento ES

P3 · EN → EN · Álgebra

Given $f(x)=x^3-5x^2+ax+b$ with factors $(x+2)$ and $(x-3)$, what is its complete factorization?

Respuesta esperada: (x+2)(x−3)(x−4). Fuente: math:en:AI-MO/QA_Full/01714/945 | Parquet 12, fila 97107 · documento EN

P4 · ES → EN · Cross-lingual

Un condensador de 10 µF con carga inicial de 20 µC se descarga mediante una resistencia de 1 kΩ. ¿Cuánto tarda en llegar a 10 µC?

Respuesta esperada: 6,9 ms. Fuente: physics:en:126b7827-6197-4306-b80c-a5ccc4ce5e26 | test.json:987 · documento EN

P5 · EN → EN · Ondas

A 25 g string under 20 N tension takes 50 ms to transmit a pulse along its length. What is the string length?

Respuesta esperada: 2 m. Fuente: physics:en:0dbd4d82-1bd4-4ce0-87f8-0b6089640187 | test.json:513 · documento EN

7. Evaluación y riesgos pendientes

En la ejecución final se comprobará el recuento exacto de chunks por idioma y la calidad de la colección; se reservará un conjunto de consultas para medir hit@k/recall@k y el efecto de filtros y estrategias de indexación. Riesgos: licencias de documentos originales (especialmente libros de PhysicsEval), errores de solución, diagramas omitidos, sesgo por fuente y fuga entre problemas duplicados. Se registrará el origen y se limitará el acceso al corpus mientras no se aclaren los permisos.

Fuentes: https://huggingface.co/datasets/friederrr/PolyUniMath · https://huggingface.co/datasets/IUTVanguard/PhysicsEval

Anexo (a partir de la página siguiente): salida completa, sin modificaciones, de check_project.py.

ANEXO · SALIDA COMPLETA DE check_project.py

Ejecución facilitada por el estudiante. Se reproduce íntegra, incluida la nota final de estimaciones.

```
======================================================================
check_project.py - project proposal check
======================================================================
Sample:         data/corpus_candidato/muestra_check_project.csv
Model:          intfloat/multilingual-e5-base
Total documents: 16,000 (your estimate for the full corpus)
Query prefix:    "query: "
Passage prefix:  "passage: "
Python 3.12.7 | sentence-transformers 6.1.0 | torch 2.11.0+cu128 | Windows AMD64

1. MODEL
  Device:           cuda:0
  Dimension:        768
  max_seq_length:   512
  Tokens taken by the passage prefix and special tokens: 4 -> 252 text tokens per 256-token chunk

2. SAMPLE (300 documents)
  language     docs      words     tokens    chunks  % chunks
  en            188     77,100    168,244       749    75.8%
  es            112     22,625     47,219       239    24.2%
  Words per full 256-token chunk: 117 (the last chunk of each document is usually shorter)

3. FULL CORPUS (estimate)
  Chunks per document (sample average): 3.3
  Estimated 256-token chunks: 52,693

4. SPEED (encoding 128 chunks of your sample; please wait)
  128 chunks in 1.6 s -> 82.2 chunks/s
  Estimated time for the full corpus: 0 h 10 min (embeddings only; reading, chunking and inserting not included)

5. REQUIREMENTS (brief, Part 1)
  [OK] Dimension 768 <= 1024 (section 4.1)
  [OK] max_seq_length 512 >= 512 (section 4.1)
  [OK] Languages in the sample: 2 >= 2 (section 3)
  [OK] Language 'en': 75.8 % of the chunks >= 20 % (section 3)
  [OK] Language 'es': 24.2 % of the chunks >= 20 % (section 3)
  [OK] Documents: 16,000 >= 1,000 (section 2.1)
  [OK] Chunks: 52,693 >= 25,000 (section 2.1; recommended ~50,000)
  [OK] Documents in the sample: 300 >= 50 (with fewer, the estimates are unreliable)

Remember: these are estimates from a sample. Copy this whole output into your proposal.
```